


Relatório 10 - Lidando com Dados do Mundo Real (II)

Felipe Fonseca

Descrição da atividade

KNN:

O primeiro tema apresentado foi o KNN, ou K-Nearest Neighbors, que significa utilizar dados existentes para achar os “vizinhos” mais próximos de um outro dado, ou então classificar um novo dado com base nos seus vizinhos. K representa o quanto você vai expandir a busca, quanto maior, mais longe você vai buscar. O objetivo é achar o limite, onde o K representa melhor a característica do dado, porém sem deixar que dados “errados” interfiram.



PCA:

PCA é a análise dos componentes principais, o objetivo desse método é analisar os componentes e decompor os valores de forma a simplificar os dados para que possamos entender, porém sem perder sua “essência”. Por exemplo, tentar reduzir um objeto de 4 dimensões para 3 ou 2.

Data Warehouse:

Data warehouse é um armazém de dados, como se fosse um banco de dados, cujo objetivo é receber informações de vários lugares diferentes e conseguir conectar esses dados. O apresentador apontou que uma das principais diferenças entre um analista de dados e um cientista de dados, é que o analista normalmente utiliza de ferramentas visuais para extrair gráficos e relatórios diretamente do banco de dados, enquanto o cientista escreve códigos que realizam análises avançadas para aplicar IA sobre esses dados. Dentre os problemas citados de um data warehouse, estão a normalização de dados, pois é necessário conectar os dados de vários lados diferentes que vem de uma empresa, e a escalabilidade, pois quanto maior a empresa, mais difícil se torna processar os dados.

Ainda no mesmo vídeo, o apresentador fala sobre a mudança no tratamento de dados, onde anteriormente primeiro os dados são transformados para depois serem lidos, porém hoje em dia, os dados primeiro são carregados, e depois são transformados e tratados. A diferença é que no modelo antigo transformar os dados demandam muito processamento e demorava para que os dados pudessem ser carregados, já no modelo atual, os dados são todos jogados primeiramente, e apenas depois limpar os dados, pegando apenas o que for necessário invés de já tratar tudo de uma vez.


Reinforcement Learning:

Esse método apresentado consiste em criar um agente que navegue em um ambiente sem ser programado com regras fixas, invés disso, colocar apenas algumas regras como se fossem feedbacks e deixar que o agente percorra o caminho e aprenda por conta própria. No vídeo o exemplo é utilizado com um jogo do pacman, onde ele pode se mover para 4 direções, porém possui obstáculos, alguns fantasmas, e comidas para pegar. Se a ação é negativa, o feedback é negativo, e assim vai.

O método q-learning aplica exatamente isso, colocando todas as condições possíveis, como se fosse uma tabela para que o agente consulte e veja qual a melhor opção a se fazer no estado atual dele. O método ainda contém algumas outras variáveis como o fator aleatoriedade. Para que o agente pelo menos conheça todos os caminhos, sempre existe a chance dele não seguir a tabela e apenas se mover de forma aleatória para qualquer um dos cantos e ver o que dá.

Matriz de confusão:

A matriz de confusão serve para analisar a eficácia de um modelo de previsão, ou seja, ela analisa a quantidade de acertos e erros cometidos para a quantidade de previsões verdadeiras ou falsas feitas pela IA. Um exemplo aleatório seria "existe um semáforo nessa imagem?" Então é feito uma análise em uma tabela, quantas vezes a IA disse que tinha um semáforo? quantas vezes ela acertou e errou ao fazer essa afirmação? Essa é a ideia da matriz de confusão.



O objetivo ideal ao fazer uma matriz dessa, é que o resultado seja uma diagonal, conectando os verdadeiros positivos e os verdadeiros negativos, concluindo que o modelo possui uma boa acurácia, tendo mais acertos do que erros.

Classificadores de medição:


As principais métricas utilizadas são Recall e Precision, ao fazer um modelo de previsão, devemos escolher em qual deles focar. Recall é focado em diminuir os resultados Falsos Negativos, ou seja, é melhor você errar acusando do que errar não acusando. Um exemplo seria uma suspeita de site fraudulento, é melhor que o navegador bloqueie o acesso e erre, do que deixe o usuário acessar e seja exposto depois. Já o Precision foca no contrário, onde é melhor o falso negativo do que o falso positivo, por exemplo, em um tribunal de justiça, o suspeito é inocente até que se prove culpado, nesse caso, o recomendado para o modelo é que é melhor errar dizendo que um culpado é inocente do que dizendo que um inocente é culpado.

A também o Specificity, que é uma medida equilibrada entre as duas anteriores, porém o apresentador do vídeo deixa um alerta bem grande quanto a essa medida, dizendo que é um "atalho preguiçoso", e que em 99% dos casos é melhor analisar o problema e escolher uma das outras duas. E o RMSE mede os erros, penalizando apenas os erros maiores, mas não diferenciando entre falsos positivos ou negativos, sendo uma métrica bruta de certo e errado.

Além dessas medidas, existe uma avaliação visual chamada de ROC que coloca o Recall com a taxa de falsos positivos, em vários limites de decisão (thresholds). O objetivo do modelo é se curvar ao máximo para próximo do canto superior esquerdo, isso é, se a curva estiver colada nas bordas do gráfico, o modelo é perfeito, porém se ele for uma reta diagonal, significa que ele não aprendeu nada. A AUC é a área que existe embaixo dessa curva, ela representa a probabilidade do modelo dar uma pontuação mais alta a um positivo aleatório do que um negativo aleatório. Quanto mais próximo de 1, melhor, ou seja, 1 seria o modelo perfeito.

Viés e variância:

São dois conceitos também utilizados para medir a precisão de um modelo de previsão, sendo viés uma medição do quão longe as previsões estão do valor correto, e a variância sendo a dispersão das previsões, ou seja, quão espalhados estão os resultados. Na prática, se um modelo tem alto viés significa que ele está sempre errando para algum lado da previsão, ou seja, não aprendeu de verdade os padrões dos dados, agora se o modelo possui alta variância, significa que ele é muito sensível aos dados, ou seja, se os dados de entrada mudam nem que seja pouco, a previsão muda muito.



Bias-Variance Tradeoff

Quando o modelo tem alto viés é chamado de underfitting, quando tem alta variância ele é chamado de overfitting.

O objetivo no final das contas é diminuir esse erro total, mas novamente, é muito difícil chegar em um modelo complexo, então na maioria das vezes a abordagem a ser tomada é olhar qual dos dois é o menos pior de se ter no modelo.

Limpeza de dados:

No vídeo o apresentador fala que na maior parte do tempo, o cientista de dados vai ficar preparando dados brutos, pois muitas vezes é melhor focar em melhorar os dados do que os modelos de treinamento. Aqui estão os tipos citados no vídeo:

Tipo de Problema	O que é	Exemplo	Decisão

Outliers	Valores exagerados que fogem muito do padrão normal.	Um usuário que clica rápido demais.	Remover (se não refletir o comportamento real que você estuda).
Faltantes	Dados que simplesmente não existem na linha.	Um registro de acesso onde o campo de origem está em branco.	Decidir se descarta a linha ou cria uma categoria nova.
Maliciosos	Dados criados propositadamente para enganar o sistema.	Pessoas criando contas falsas para aumentar a nota de um produto.	Identificar os padrões de ataque e filtrar esses dados.
Errôneos	Dados errados causados por bugs ou falhas técnicas.	Um software que perde o ID da sessão do usuário no meio do caminho.	Investigar a fundo para achar o bug no sistema que gera o dado.
Irrelevantes	Dados reais, mas que não servem para sua pergunta atual.	Dados de usuários do mundo todo quando você só quer analisar Nova York.	Tirar tudo o que não está no escopo da sua análise.
Inconsistentes	A mesma informação escrita de jeitos diferentes.	Endereços variados.	Normalizar.
Formatação	Diferenças na estrutura do dado.	Datas americanas misturadas com datas globais.	Converter tudo para um formato único.

Normalização de dados:

Esse é o vídeo mais tranquilo do card, ele apenas fala sobre os cuidados que devemos ter, ou seja, sempre verificar como estão os dados do projeto, sempre olhar a documentação, ver as fontes, sempre lembrar de fazer as conversões na hora de mostrar os resultados finais etc.

Engenharia de atributos:

Segundo o vídeo, é basicamente o processo de selecionar os dados que serão usados para treinar um modelo, por exemplo, se quiser prever o salário de uma pessoa, esses atributos podem ser idade, talvez endereço, peso e altura, etc.

Técnicas para dados faltantes:

Nesse vídeo ele fala sobre técnicas utilizadas para solucionar o problema de quando estão faltando dados nas colunas. Ele diz que uma abordagem simples, mas talvez não tão boa, seria substituir pela média, mas ela pode ser cega às vezes, quando a muitos valores errados muito distantes (outliers) o recomendado pode ser utilizar a mediana, que é menos afetada pelos valores extremos, porém isso não significa que não tenha riscos, por isso, para cada dado é essencial ver e analisar qual método será utilizado.

É citado alguns métodos para substituir esses valores ausentes utilizando as próprias informações aprendidas pelo modelo, como por exemplo o KNN, o Deep learning ou o MICE. Porém a solução ideal ainda seria evitar os dados ausentes, ou seja, coletar ainda mais dados de boa qualidade.

Lidando com dados desbalanceados:

Essa parte trata de avisar sobre alguns métodos utilizados para lidar quando os dados não são balanceados, ou seja, quando uma situação é muito rara de acontecer e é necessário que o modelo aprenda ela. Por exemplo, em um exame qualquer, se a taxa for de 99.9% verdadeiro, porém 0.1% falso, isso significa que a acurácia do modelo provavelmente vai ser próximo disso, e ele vai acertar quase 99.9% das vezes, porém nas poucas vezes que ele deveria acertar, ou seja, o 0.1%, ele não, na prática, isso torna o modelo inútil, pois na hora em que ele deveria fazer a diferença ele sempre vai errar.

Para evitar isso, existem algumas técnicas que podem ser utilizadas. A primeira citada foi o Oversampling, onde você cria cópias dessa minoria a fim de aumentar a amostra de treinamento para o modelo. O segundo método seria o Undersampling, onde você joga fora os dados da classe que é maioria, tática que segundo o próprio apresentador não é recomendado, pois nunca é recomendado jogar dados fora. O terceiro método seria o do SMOTE, onde ele utiliza o KNN para criar novos dados que sejam de acordo com as regras da classe minoria. E o quarto é o Thresholding, ou seja, você ajusta a porcentagem de confiança para dar a resposta, por exemplo, se o modelo colocar 20% de chance de uma transação ser fraude, você marca ela como fraude, o Thresholding significa fazer o ajuste dessa porcentagem, e aí obviamente esse valor seria diferente para cada caso de acordo com a necessidade do projeto.

Técnicas para lidar com dados:

Binning: técnica de agrupamento para dados numéricos, exemplo: invés de utilizar as idades exatas, como 25 anos, coloca em classificações de faixa etária, como por exemplo "faixa dos 20 aos 30 anos". Essa técnica serve para ajudar a mascarar imprecisões ou erros nos dados, além de simplificar os dados, porém pode acabar perdendo informações no processo.

Quantile Binning: é uma variação do binning para criar os grupos, que coloca uma regra de que todos os grupos tem que ter o mesmo número de amostras, distribuindo os dados de forma igual, ou seja, utilizando ainda o exemplo de idade, as faixas teriam que ser ajustadas para que todas essas faixas de idade tenham a mesma quantidade de pessoas.

Transforming: Aplicar funções matemáticas aos dados, como a transformação logarítmica.

Encoding: Criação de uma representação binária para valores como o de categorias, pois os modelos não entendem categorias de textos por exemplo.

Scaling e Normalização: ajustar os dados para que fiquem comparáveis, normalmente entre 0 e 1.

Shuffling: é a técnica de misturar a ordem dos dados, embaralhar, para que fique aleatório.

Conclusões

Nesse card foram tratados de várias práticas e testes que podem ser realmente utilizados na vida real, como as técnicas de normalização, conselhos como as técnicas para lidar com os dados, etc.

Até agora foi o card mais prático que tive, que realmente colocou a mão na massa em algo que realmente vai ser muito importante, e deu pra perceber isso na prática, onde fiz testes com um banco de dados sobre fraudes em cartões de crédito.

As técnicas que mais me impressionaram foram justamente as que eu utilizei na prática, ou seja, o KNN para conseguir classificar os dados, a matriz de confusão que foi muito útil para saber onde estava os problemas da forma que eu estava treinando, e a técnica de normalização de dados, que foi o que corrigiu a grande quantidade de erros que estava dando no treinamento.

No geral, foram atividades muito bem desenvolvidas e com conhecimentos realmente muito interessantes que serão úteis no treinamento de modelos futuramente..

Referências

Imagem de ilustração de viés e variância:

<https://bixtecnologia.com.br/como-entender-vies-e-variancia-em-modelos-preditivos/>

- 1. 🧑🏫 [K-Nearest-Neighbors Concepts](#)
- 2. 🧑🏫 **Activity** [Using KNN to predict a rating for a movie](#)
- 3. 🧑🏫 [Dimensionality Reduction; Principal Component Analysis \(PCA\)](#)
- 4. 🧑🏫 **Activity** [PCA Example with the Iris data set](#)
- 5. 🧑🏫 [Data Warehousing Overview ETL and ELT](#)
- 6.1 📄 [Pac-Man Example.html](#)
- 6.2 📄 [Python Markov Decision Process Toolbox.html](#)
- 6.3 📄 [Cat and Mouse Example.html](#)
- 6. 🧑🏫 [Reinforcement Learning](#)
- 7. 🧑🏫 **Activity** [Reinforcement Learning & Q-Learning with Gym](#)
- 8. 🧑🏫 [Understanding a Confusion Matrix](#)
- 9. 🧑🏫 [Measuring Classifiers \(Precision, Recall, F1, ROC, AUC\)](#)

- 1. 🧑🏫 [BiasVariance Tradeoff](#)
- 2. 🧑🏫 **Activity** [K-Fold Cross-Validation to avoid overfitting](#)
- 3. 🧑🏫 [Data Cleaning and Normalization](#)
- 4. 🧑🏫 **Activity** [Cleaning web log data](#)
- 5. 🧑🏫 [Normalizing numerical data](#)
- 6. 🧑🏫 **Activity** [Detecting outliers](#)
- 7. 🧑🏫 [Feature Engineering and the Curse of Dimensionality](#)
- 8. 🧑🏫 [Imputation Techniques for Missing Data](#)
- 9. 🧑🏫 [Handling Unbalanced Data Oversampling, Undersampling, and SMOTE](#)
- 10. 🧑🏫 [Binning, Transforming, Encoding, Scaling, and Shuffling](#)