

Relatório 13 - Predição e a Base de Aprendizado de Máquina (II)

Felipe Fonseca


1. Introdução

O objetivo desse card foi ver vários métodos de Machine Learning e modelos de algoritmos que podemos utilizar para treinar dados, desde os mais simples como regressão linear até alguns mais complexos como XGBoost. A ideia era entender principalmente a ideia de cada um dos modelos e como aplicá-los em Python, utilizando bibliotecas como scikit-learn que facilitam muito a vida do programador.

2. Desenvolvimento

Nesse card foram desenvolvidas várias técnicas utilizadas na ciência de dados para treinar dados e prever resultados. Além de apenas rodar os modelos, foi ensinado pelo instrutor algumas técnicas para preparação de dados, como o train test split, ou seja, a técnica de separar uma parcela, normalmente próxima de 20% dos dados para fazer testes, e o restante para fazer o treinamento dos dados, assim conseguimos verificar a porcentagem de acertos que o modelo treinado consegue fazer para dados desconhecidos. Além disso, também foi falado sobre o r-squared, que é uma fórmula para avaliar como o modelo está performando, ou seja, o resultado dará um número de 0 à 1, onde 0 ele tem 0% de chance de acerto e 1 ele tem 100% de chance de acerto ao fazer uma previsão.

Outro importante conceito que foi aprendido nesse card foi Machine Learning Supervisionado e Não Supervisionado. Não Supervisionado é quando você não dá nenhuma resposta aos modelos para que eles aprendam, apenas jogamos os dados e com as observações que eles fazem por conta própria eles devem aprender, é recomendado quando você não sabe a relação que está procurando. Supervisionado é quando você conhece os atributos e sabe a resposta, então você passa as respostas corretas para que o modelo aprenda e a partir disso possa aprender a prever as respostas para novos valores desconhecidos.



Os modelos estudados no card foram Regressão linear, polinomial e múltipla, Naive Bayes, K-means Clustering, Árvores de decisão, Ensemble Learning e Support Vector Machines.


- **Regressão:** tentar encaixar uma linha de forma que represente os dados, e utilizar essa mesma linha para prever novos valores.
- **Regressão Linear:** é uma função simples, ou seja, traça uma linha reta entre os dados.
- **Regressão Polinomial:** usada quando os dados possuem curvas no gráfico, podemos utilizar polinômios de primeiro grau (reta), de segundo grau, terceiro, quarto etc. Sempre procurando o que mais se adapta aos dados.
- **Regressão Múltipla:** considera mais do que um atributo. Como por exemplo tentar prever o valor de um objeto, existem mais do que 1 variável para prever o valor de um objeto na maioria das vezes, a regressão múltipla considera todos esses fatores.
- **Naive Bayes:** Técnica utilizada para classificação, na aula testamos ela em um filtro de spam. Essa técnica se baseia na probabilidade de algo acontecer com base em alguma outra coisa. O caso utilizando e-mails é um bom

exemplo, apesar de parecer ingênuo (naive), analisando a probabilidade das palavras de forma isolada para prever um e-mail inteiro funciona muito bem.

- **K- means clustering:** é o único método de aprendizado não supervisionado que testamos no card. O algoritmo tenta agrupar os dados (clusters) por similaridade entre eles, porém sem que a gente diga o que eles são.
- **Entropia e Árvore de decisão:** A entropia é uma medida de desordem dos dados, já uma árvore de decisões vai atribuindo pontos para as variáveis de escolha conforme condições para no final tomar uma decisão. O objetivo de uma árvore de decisão é justamente diminuir a entropia a cada passo.
- **Random Forest:** é a técnica de utilizar várias árvores de decisões, e cada árvore utiliza uma parte aleatória dos dados e “vota” em uma decisão final.
- **Ensemble Learning:** significa usar vários modelos de machine learning para obter uma decisão final. Bagging é quando se treina vários modelos iguais em partes aleatórias dos dados e junta os resultados, Boosting é quando se faz uma sequência de modelos onde cada um tenta corrigir os erros do anterior, Bucket of Models é quando testamos diferentes tipos de modelos e escolhe o melhor, e Stacking combina as previsões de vários modelos para gerar uma resposta final mais precisa.
- **XGBoost:** um método de floresta onde cada árvore de decisão busca aperfeiçoar com base nos erros da última árvore, lidando com valores faltantes, evitando o overfitting.
- **Support Vector Machines (SVM):** funciona desenhando linhas para separar os dados, como se fosse o k learn method, com a diferença que esse é supervisionado, ou seja, ele já sabe as respostas.

Na prática eu fiz um teste com 3 modelos diferentes em um dataset de jogadores de futebol para prever o valor do jogador com base em seus números. Porém não consegui obter um bom resultado nas previsões. A parte mais complicada foi a formatação do data frame, onde existiam muitos valores vazios, o que fez com que isso importasse muito nos valores das previsões.

Fluxograma do código prático



3. Conclusão

Esse card cobriu a base dos modelos em que se usa em ciência de dados para previsão de valores. O principal aprendizado é de que não existe um algoritmo correto a se usar, assim como não existe um algoritmo perfeito, mas

sim ferramentas diferentes, e modelos diferentes, que devemos combinar e analisar qual se encaixa melhor para a situação que tivermos em mãos.

4. Referências

Videoaulas do card;

Documentação do Scikit-Learn (pouquíssimas vezes);