

Relatório 19 - Como Estamos Ensinando os Computadores a Compreender Fotos (III)


Felipe Fonseca

1. Introdução

Esse card teve um vídeo sobre o desenvolvimento e a evolução da visão computacional ao longo de alguns anos de desenvolvimento da equipe da palestrante, além de mostrar de onde vieram as ideias da rede neural convolucional, e as semelhanças e diferenças entre o aprendizado humano e o aprendizado de máquina quanto a visão.

2. Desenvolvimento

A palestrante começa dando exemplos de como visão computacional ainda é um desafio gigante para a computação, pois na época onde o vídeo foi lançado (especificamente no ano de 2015), ainda não existiam ferramentas que pudessem entender as fotos como já existem atualmente, mas independente disso, ainda é sim um desafio mesmo nos dias de hoje fazer com que o computador entenda uma imagem.



A palestrante fala sobre a ideia dela e da equipe de como desenvolver a visão computacional, onde é ensinado as formas e cores do gato para a máquina, não através de forma estática, mas sim com fotos, e deixando que a própria máquina aprenda a identificar. A palestrante disse que essa ideia veio da observação da própria natureza, pois uma criança por exemplo aprende exatamente dessa forma, através da observação.



Ela cita um número de mais de milhões de imagens de gatos que foram utilizadas para treinar um modelo para identificação dos mesmos, com mais de 40 mil trabalhadores envolvidos ao redor do mundo para o tratamento dessas imagens.

Posteriormente, é citado sobre a arquitetura do algoritmo em si, onde a apresentadora cita as Redes Neurais Convolucionais, em um processo semelhante ao cérebro, e como nesse algoritmo específico foram utilizados bilhões de parâmetros e milhões de conexões. Depois a mulher mostra exemplos de várias imagens identificadas por AI, alguns resultados propositalmente errados, mas muitos resultados realmente surpreendentes, como o reconhecimento de modelos exatos de carros através de câmeras instaladas nas ruas.

Após muitos exemplos, ela mostra um trunfo final: a capacidade de conectar palavras em sentenças humanas com elementos de uma imagem, tendo como resultado um modelo de inteligência artificial que consegue gerar uma sentença humanizada recebendo uma imagem desconhecida, um resultado que pode parecer não tão incrível hoje em dia com a popularização de LLMs como o ChatGPT ou o Gemini, mas que em 2015 era o ápice da tecnologia, e mesmo hoje, treinar um modelo para conseguir esse resultado é um processo extremamente complicado.

3. Conclusão

Essa palestra foi interessante para dar mais uma ideia geral do que é visão computacional, mas principalmente do esforço que é necessário para fazer um modelo que realmente seja bom o suficiente para ter uma utilidade, com números absurdos de dados, trabalhadores, dinheiro investido em GPUs e principalmente em tempo para conseguir executar tudo isso. Além é claro da evolução desse modelo citado pela apresentadora desde seu início em 2007 até a apresentação em 2015.

4. Referências

Vídeo do Card: <<https://www.youtube.com/watch?v=40riCqvRoMs>>.