

Relatório 21 - Visão Computacional (III)


Felipe Fonseca

1. Introdução

Este relatório apresenta um resumo dos principais conceitos de Visão Computacional e Deep Learning abordados nesta etapa do curso. O objetivo é descrever desde o funcionamento básico de redes neurais e tensores até técnicas mais complexas. Serão detalhados processos de manipulação de imagens, arquiteturas de CNNs e o uso de modelos avançados como Autoencoders e Deep Fakes.

2. Desenvolvimento

Fundamentos de Deep Learning: inicialmente são apresentados alguns conceitos de Deep Learning. Deep Learning em si é um campo em Machine Learning que utiliza de redes neurais artificiais para aprender e conseguir resolver problemas, tendo já aplicações na indústria de saúde, transporte, linguagens, etc.



Depois foram apresentados o tensor, que é um objeto utilizado em matemática, física, e também em computação. Bem resumido, é uma outra forma de mostrar números, sendo bem mais eficiente para tratar de objetos com múltiplas dimensões.


Redes Neurais: o workflow para trabalhar com redes neurais se resumem a definir um objetivo de algo que deve ser previsto, pegar objetos que afetam a previsão e

preparar os dados para lidar com isso. Já a arquitetura em uma rede neural se resume na forma em que as camadas estão dispostas, CNN é um exemplo de arquitetura de rede neural.

Nessa sessão novamente são ensinados os conceitos básicos como o que é um dataset, o que é uma função de perda (loss), o que é o otimizador, funções de ativação mais utilizadas como sigmóide e relu, e como funciona o treinamento de uma rede neural por épocas, mas de forma bem resumida.

Imagens: nessa seção o foco foi na manipulação de imagens até o treinamento, mas sem utilizar a arquitetura de uma cnn, e sim com uma arquitetura padrão mesmo. Dentre os conceitos apresentados foi na manipulação dos objetos utilizando a biblioteca pytorch invés do tensorflow como eu havia aprendido anteriormente. Quanto a algumas dicas, o apresentador fez questão de falar da importância da normalização dos valores ao lidar com imagens, que ajuda não só por conta de lidar com números menores na rede neural, mas também ajuda com que fatores de iluminação e diferenças de qualidade das câmeras não afetem o treinamento.


CNN: depois foram apresentados alguns exemplos de utilização das CNNs para analisar imagens. Tudo que foi dito aqui já havia sido citado em cards anteriores, como a capacidade de identificar as principais características, como funciona a arquitetura de pooling e convolução, flattening, etc. Quanto ao código, fizemos uma rede neural simples com a biblioteca pythorch, utilizando um esquema diferente, invés de fazer camada por camada da rede neural, agrupamos as camadas por bloco em uma função, e depois chamamos na rede neural.



Auto Encoders: depois foram citados os autoencoders, que são, resumidamente, um tipo de rede neural. Sua arquitetura consiste em um encoder e um decoder. O encoder é o que comprime a imagem, e o decoder é o que retorna para o tamanho original. Depois o apresentador mostrou o VAE, um novo tipo de autoencoder que aprende uma distribuição de probabilidade dos dados, gerando 2 vetores, um de média e um de variância. A importância disso é que eles podem produzir imagens inéditas e naturais, bem melhores que a de um autoencoder normal.

Outros conceitos: na parte final do card, foram apresentados outras 3 utilidades de rede neurais com imagens. A primeira foi o Neural Style Transfer, transferência de estilo neural, ou seja, é uma técnica para aplicar o estilo de uma imagem a outra. A segunda que é a mais famosa, e é a mais interessante é o deep fake, que é a capacidade de substituir partes de uma imagem por outra de forma natural, o exemplo visto na aula era a troca de rostos de 2 pessoas. E por fim foi visto o Image Colorization, que é a técnica de prever e adicionar cores a imagens cinzas.

Exemplo de arquitetura de um modelo para Deep Fake:



3. Conclusão

Esse card mostrou como a Visão Computacional evoluiu com o uso de Deep Learning, permitindo realizar tarefas que antes eram extremamente difíceis. Aprendi que, além de entender a arquitetura das redes neurais, é fundamental saber preparar e normalizar os dados para obter bons resultados. O uso de bibliotecas como o PyTorch facilita a organização do código em blocos, tornando o desenvolvimento mais eficiente, porém não achei ela tão prática e fácil de entender quanto o TensorFlow. Mas a parte mais interessante foi as técnicas apresentadas ao final, sendo técnicas que possibilitam muitas coisas, mas ao mesmo tempo exige responsabilidade de quem utiliza.

4. Referências

Vídeos do Card