

Relatório 26 - Comparando Modelos de Machine Learning e SHAP

Felipe Fonseca

1. Introdução

Nesse card foram desenvolvidas atividades com foco na comparação de modelos de machine learning através de métricas de validação, e também na forma de interpretar modelos utilizando a biblioteca SHAP. A primeira parte aborda conceitos fundamentais de classificação como matriz de confusão, acurácia, precisão, recall, especificidade e curva ROC. A segunda parte apresenta o SHAP como ferramenta para entender como os modelos tomam suas decisões. Por fim, a prática une esses dois mundos aplicando as métricas e o SHAP no dataset Íris, tentando utilizar alguns métodos de avaliação binários em um dataset multiclasse.

2. Desenvolvimento

2.1 Comparando Modelos de Machine Learning

O objetivo principal dessa parte do card foi entender como comparar modelos de machine learning através de métricas de validação. O foco do curso é em problemas de classificação, que consiste na previsão de rótulos ou categorias, diferente da regressão, que é voltada para a previsão de valores numéricos.

		0 Predição 1	
Valores Reais	0	Verdadeiro Negativo	Falso Positivo
	1	Falso Negativo	Verdadeiro Positivo

A principal métrica apresentada foi a Matriz de Confusão. Ela funciona como um cruzamento entre os dados reais e os dados previstos pelo modelo, identificando onde as previsões acertaram e onde erraram. Os quatro valores que compõem essa matriz são:

- Verdadeiro Negativo: a previsão era negativa, e acertou.
- Falso Positivo: a previsão era positiva, e errou.
- Falso Negativo: a previsão era negativa, e errou.
- Verdadeiro Positivo: a previsão era positiva, e acertou.

A partir desses valores da matriz de confusão, é possível calcular as outras métricas importantes:

Acurácia: é a métrica mais simples, calculada dividindo a quantidade de acertos pela quantidade total de respostas. Pela matriz de confusão, isso é feito somando os valores verdadeiros (verdadeiro positivo + verdadeiro negativo) e dividindo pela soma de todos os valores da matriz.

Precisão: apesar de causar confusão com a acurácia, são coisas diferentes. A precisão olha para a afirmação feita pelo modelo. Por exemplo, de todos os emails classificados como spam, quantos realmente eram spam? Pela matriz de confusão, é calculada dividindo os verdadeiros positivos pela soma dos verdadeiros positivos com os falsos positivos.

Recall: é quase o contrário da precisão. Aqui, olhamos para o que de fato aconteceu. Por exemplo, de 1000 emails de spam que foram enviados, quantos o modelo conseguiu identificar corretamente? Pela matriz de confusão, é calculado dividindo os verdadeiros positivos pela soma do verdadeiro positivo com o falso negativo.

Especificidade: enquanto o recall olha para quantos spams o modelo conseguiu capturar, a especificidade olha pelo outro lado: de 1000 emails que não eram spam, quantos o modelo acertou que realmente não eram spam? Pela matriz de confusão, é calculada dividindo o verdadeiro negativo pela soma do verdadeiro negativo com o falso positivo.

2.2 Cutoff e Curva ROC

O Cutoff é a porcentagem mínima que vai ser considerada na previsão do modelo. Por exemplo, com um cutoff de 0.8, em uma previsão de email sendo ou não spam, o email só será classificado como spam se a probabilidade dele ser spam for maior que 80%.


Evento	Probabilidade	Status
Chover	80%	Sim
Fazer sol	45%	Não
Nevar	5%	Não
Ventar muito	60%	Não
Nublar	50%	Não

Essa tabela acima mostra o status com base na probabilidade com cutoff = 80%. Agora no exemplo abaixo, teremos os mesmos eventos, com as mesmas probabilidades, mas com os status diferentes, devidos apenas no cutoff, que será igual a 50%.

Evento	Probabilidade	Status
Chover	80%	Sim
Fazer sol	45%	Não
Nevar	5%	Não
Ventar muito	60%	Sim
Nublar	50%	Sim

A Curva ROC foi o ponto central de toda a teoria apresentada. Ela nada mais é do que uma navegação pelos valores do cutoff, marcando os pontos do Recall no eixo Y e o valor de 1 menos a especificidade no eixo X. Olhando para a área embaixo da curva, o modelo perfeito seria representado por um quadrado com área 1. Uma linha reta na diagonal seria o mesmo que um modelo aleatório, algo que representa um

resultado péssimo. Normalmente, o melhor modelo é aquele que possui a maior área embaixo da curva ROC.



2.3 SHAP


O SHAP é uma biblioteca utilizada para interpretar como modelos de machine learning tomam suas decisões. Ele é especialmente útil para aqueles modelos que apenas recebem os dados e retornam a previsão pronta, sem expor a probabilidade que comprova a previsão, ou as características que têm maior peso para a decisão.

Na aula, o SHAP foi aplicado sobre um classificador LinearSVC treinado no dataset Breast Cancer, que é um problema de classificação binária para prever se um tumor é maligno ou benigno. O fluxo de uso foi o seguinte: após treinar o modelo normalmente, é criado um explainer do SHAP, que recebe o modelo e um resumo representativo dos dados de treino (gerado com o kmeans). A partir daí, são calculados os `shap_values` para os dados de teste, que indicam para cada variável o quanto ela influenciou na decisão final do modelo.

Com esses valores, é possível gerar dois tipos de gráficos bem úteis: o summary plot, que mostra a importância geral de cada característica para o modelo ao longo de todas as previsões, e o force plot, que foca em uma previsão específica e mostra quais variáveis empurraram a decisão para um lado ou para o outro. Também é possível calcular a média absoluta dos shap values para ranquear as variáveis de maior influência, gerando um ranking de importância de features.


2.4 Prática

Na prática eu tentei aplicar os dois conteúdos utilizando o dataset Íris, que é um problema de classificação multiclasse com 3 categorias de flores. O modelo escolhido foi também o LinearSVC.




Primeiro eu carreguei o dataset do íris através do sklearn e fiz a divisão de treino e teste utilizando o split também do sklearn.

Depois treinei o modelo e avaliei as métricas: acurácia, precisão e recall, calculando todas com o sklearn. Depois gerei a matriz de confusão para visualizar os acertos e erros do modelo por classe. Por ser um problema multiclasse, o cálculo das métricas utilizou a média macro, que trata todas as classes com o mesmo peso independente do volume de dados.




Como é possível ver na matriz de confusão, houve apenas um valor confundido no teste, obviamente que por ser um dataset pequeno os valores tendem a ser mais acurados, mas mesmo assim já é um bom indicador.

Depois apliquei o SHAP da mesma forma que foi feito na aula, criando o explainer, calculando os shap_values e gerando os gráficos de summary_plot e force_plot para entender quais características do dataset Íris mais influenciaram as previsões do modelo.



Como é possível ver, o comprimento das pétalas é o fator que mais pesa para classificar as plantas.

Por fim, implementei as curvas ROC para as 3 classes usando a abordagem de 1 contra o resto, onde para cada classe, ela é tratada como positiva e todas as outras como negativo, tive de implementar dessa forma porque a curva Roc trabalha com valores binários, e não com multiclass. Como o LinearSVC não retorna as probabilidades, foi utilizado o decision function para obter os scores de decisão. Para cada classe foi calculada a curva ROC e sua respectiva AUC, gerando um gráfico com as três curvas.



Como é possível ver aqui também, por haver poucos dados, não tem o suficiente para gerar uma curva, o que fez o gráfico ficar com um aspecto quadrado. Além disso, como para 2 classes, o acerto foi de 100%, teve 2 linhas do gráfico fazendo o traçado perfeito.

3. Conclusão

Esse card foi muito importante para entender como avaliar e comparar modelos de machine learning de forma mais criteriosa. Ficou claro que a acurácia sozinha não é suficiente para avaliar um modelo, e que dependendo do contexto, métricas como recall ou precisão podem ser muito mais relevantes. A curva ROC foi um conceito especialmente interessante por conseguir resumir o desempenho do modelo em diferentes limiares de decisão em um único gráfico. O SHAP também foi um destaque, pois resolve um problema real que é a falta de transparência em certos modelos, permitindo entender o raciocínio por trás de cada previsão.

4. Referências

Videoaulas do Card

Documentação do Scikit-learn