

Relatório 27 - Modelos Generativos (III)

Felipe Fonseca


1. Introdução

Esse card foi a continuação do estudo sobre modelos generativos, abordando três arquiteturas principais: Auto-Encoders, Variational Auto-Encoders (VAEs) e Generative Adversarial Networks (GANs). Além disso, foi introduzido o estudo sobre GPT, passando pelos conceitos fundamentais por trás de modelos de linguagem como modelagem auto regressiva, embeddings, o mecanismo de self-attention, multi-head attention e layer normalization.

2. Desenvolvimento

2.1 Auto-Encoders

O primeiro conceito abordado foi o de Auto-Encoders. A ideia é que um encoder aprende a reduzir o input usando a convolução para uma representação mais concisa. Após isso, um decoder aprende a reconstruir os dados através dessas características para tentar formar o input original. O objetivo nesse caso é deixar os dados reconstruídos o mais parecido possível com o dado de entrada.




Um ponto interessante é que depois de terminar o treinamento, podemos descartar o encoder, pois apenas o decoder será utilizado para gerar os novos dados.

2.2 Variational Auto-Encoders (VAEs)

Os VAEs se diferenciam dos Auto-Encoders pois, ao invés de gerarem vetores fixos, eles transformam o espaço através de uma distribuição de probabilidade. Porém,


tendo aleatoriedade, não é possível calcular a derivada diretamente. Por isso, para conseguir efetuar o treinamento da rede neural, é criada uma variável externa independente, que empurra o fator aleatório para fora do fluxo principal do grafo, permitindo que a rede neural seja treinável.



2.3 Generative Adversarial Networks (GANs)

As GANs funcionam através de duas redes neurais que trabalham em conjunto: o Generator e o Discriminator. O Generator recebe um ruído aleatório como entrada e tenta transformar em dados falsos para enganar o sistema. Já o Discriminator é treinado com os dados reais para reconhecer se os outros dados são reais ou falsos.

O objetivo é que o Generator consiga criar versões falsas tão boas que o Discriminator não consiga distinguir entre essas versões e as originais. Ou seja, as duas redes treinam uma contra a outra, o que é justamente o que dá origem ao nome "adversarial".



2.4 GPT — Modelagem de Linguagem Autoregressiva

Na parte do GPT, o primeiro conceito explicado foi o modelo de linguagem autorregressivo. Nada mais é do que um modelo que consegue aprender uma distribuição de probabilidade sobre a sequência de tokens, funcionando de forma em que o modelo recebe os tokens anteriores e consegue prever o próximo.

2.5 Embeddings de Tokens e de Posição

Depois foi explicado o token embedding, que é feito através de uma lookup table, onde o tamanho do vocabulário é a dimensão do modelo. Cada token é mapeado por um vetor que representa sua identidade.

2.6 Mecanismo de Self-Attention

O principal ponto do conteúdo de GPT foi o mecanismo de self-attention, que é o ponto de foco do artigo "Attention is all you need". Basicamente esse mecanismo permite que cada token preste atenção nos outros tokens. A ideia é que a relevância entre dois tokens seja calculada de forma dinâmica, tendo três vetores para fazer as projeções:

- **Query:** o que a posição busca
- **Key:** o que ela oferece
- **Value:** o conteúdo

A atenção computa o score de compatibilidade para cada par considerando o query e o key dos valores, normaliza eles com a função softmax, e usa os scores como peso para fazer a média dos valores (Value). Na prática, se o query tem um valor semelhante ao key de outro token, então eles têm maior relação um com o outro. Dessa forma, na hora de prever o próximo token, ele consegue saber qual token se deve prestar mais atenção, qual é mais importante.

2.7 Multi-Head Attention

O multi-head attention é uma tática onde invés de prestar atenção em uma dimensão, se aplica atenções em paralelo, onde cada "head" tem suas próprias matrizes independentes (uma matriz não interfere e nem olha outra matriz). As diferentes heads podem pegar diferentes tipos de dependência entre os tokens simultaneamente, e é isso que faz seu uso ser útil.

2.8 Layer Normalization

Outro conceito que eu achei interessante foi o Layer Normalization. Nesse conceito, invés de se fazer a normalização ao longo da dimensão do batch, a normalização é feita sobre os elementos de cada vetor (na dimensão do embedding). Na prática, isso faz com que o tamanho do batch (batch size) não interfira na normalização.

2.9 LSTM vs Self-Attention

Um ponto que eu achei interessante de abordar, pois me gerou dúvida durante o estudo, foi quando utilizar LSTM e quando usar o mecanismo de attention.

Dentre as principais diferenças temos a diferença de complexidade: o mecanismo de attention possui complexidade $O(n^2)$, o que é muito custoso para memória, enquanto o LSTM possui complexidade linear. De forma geral, a LSTM é mais viável para sequências mais longas, mas apenas em termos de uso de memória, pois quando o assunto é eficiência, o mecanismo de attention é superior. Na hora de realizar o treinamento, o mecanismo de attention pode processar vários tokens em simultâneo, invés de ter que processar sequencialmente como na LSTM, além disso, no LSTM as dependências longas são difíceis de se manter.

Em termos de uso, usa-se LSTM em sequências longas, com recurso limitado, ou em datasets pequenos. Enquanto isso, o self-attention é utilizado em tarefas de NLP gerais ou quando os recursos não são limitados para escalar.

3. Conclusão

Nesse card foram abordados tanto os modelos generativos clássicos quanto os fundamentos por trás dos modelos de linguagem como o GPT. A parte que eu achei mais interessante foi o mecanismo de self-attention. A ideia de que cada token consegue "prestar atenção" nos outros e calcular dinamicamente a relevância entre eles é algo que eu achei bem elegante como solução. O fato de que o artigo "Attention is all you need" propõe exatamente isso, e esse mecanismo está na base de praticamente todos os grandes modelos de linguagem atuais, mostra como uma ideia relativamente simples pode ter um impacto absurdo. A comparação entre LSTM e self-attention também foi algo que eu quis entender melhor por conta própria, pois o conteúdo não deixou explícito quando usar um ou outro e achei importante ter essa clareza.

4. Referências

Vídeos do card.

[Pesquisa sobre LSTM vs Self-Attention](#)