

Proposta de Projeto Final

Bootcamp de Aprendizado de Máquina - Lamia

Título do Projeto:	Previsão de Valor de Mercado e Estimativa de Preço de Transferência
Nome do(a) Aluno(a):	Felipe Fonseca
Data da Proposta:	Julho de 2026

Visão Geral e Problema

Resumo:	O projeto consiste em desenvolver dois modelos de Machine Learning que trabalham em sequência para responder uma pergunta prática do futebol: quanto vale um jogador e, em uma negociação específica, por quanto ele provavelmente seria vendido? O primeiro modelo prevê o valor de mercado de um jogador com base nos seus atributos físicos, estatísticas de desempenho e o contexto do clube e liga onde atua. O segundo modelo usa esse valor como ponto de partida e, combinando com o histórico de negociação dos clubes envolvidos (quanto cada clube costuma pagar acima ou abaixo do mercado), estima uma faixa de preço provável de transferência. A principal entrega é um pipeline funcional que, dado um jogador e dois clubes, retorna o valor de mercado
----------------	--

	estimado do jogador e a faixa de preço esperada para a negociação.
Objetivo Principal:	Modelo 1: prever o valor de mercado de um jogador em euros com erro médio abaixo de 20% do valor real, avaliado no conjunto de testes. Modelo 2: dado um jogador e dois clubes (comprador e vendedor), estimar a faixa de preço provável de transferência com erro médio abaixo de 30% do valor real, avaliado no conjunto de testes.
Definição Detalhada:	O mercado de transferências do futebol europeu movimenta bilhões de euros por ano, mas os preços reais de negociação muitas vezes não correspondem ao valor de mercado estimado, e esse desvio depende muito de quem está comprando e quem está vendendo. Um clube rico historicamente paga acima do mercado; um clube com problemas financeiros vende abaixo. Eu escolhi esse problema porque é de um assunto que eu gosto e me importo, que é realmente um problema, não só no que diz respeito ao modelo 2, mas também ao modelo 1, visto que o transfermarkt realiza todas as precificações através de avaliações da comunidade. O projeto é relevante porque combina dois problemas distintos de regressão num pipeline coerente, usa dados que cobrem 26 anos de histórico, e tem uma aplicação prática direta para analistas de futebol, agentes de jogadores ou clubes que precisam embasar negociações com dados concretos.

Dados

Fonte dos Dados:	Os dados utilizados são públicos e foram extraídos do site Transfermarkt. Os datasets estão disponíveis no Kaggle: Link: Football Data from Transfermarkt
Informações dos Dados:	[Tamanho aproximado do dataset (número de amostras, features), tipos de dados (numéricos, categóricos, imagens, texto), e qualquer pré-processamento inicial planejado (ex: limpeza de missing values, normalização).] Serão utilizados mais de um dataset: • player_valuations; • appearances; • transfers; • players; • clubs; • competitions. Os dados variam entre dados numéricos, datas, e dados categóricos. Alguns pré processamentos planejados: • Calcular idade dos jogadores a partir da data de nascimento; • Agregar as aparições dos jogadores por temporada; • Calcular o perfil histórico de compra e venda dos clubes (o quanto costuma comprar/vender em % acima/abaixo do valor estimado de mercado); • Tratar valores ausentes (se tiverem); • Corte de exemplos por clubes para avaliar o perfil de negociação (clubes sem exemplos suficientes de negociações utilizarão a média da liga como

	referência).
--	--------------

Metodologia

Domínio:	Regressão.
Arquitetura(s):	Será utilizado o XGBoost para ambos os modelos. A justificativa é que o XGBoost treina muito mais rápido e exige menos ajustes que uma rede neural, além de ter melhor desempenho do que redes neurais para dados tabulados como os que serão utilizados, sendo melhor para evitar overfitting.
Métricas de Avaliação:	MAE: métrica mais fácil de interpretar de forma bruta (mostra o erro em euros) RMSE: penaliza os erros grandes, útil para identificar se o modelo comete erros absurdos em casos mais extremos, como um jogador que vale muito dinheiro ou um jogador sem valor. R²: mede o quanto ele é bom de prever valores que não estão próximos a média.
Ferramentas e Bibliotecas:	Planejo utilizar: pandas, numpy, scikit-learn, xgboost, matplotlib e talvez o seaborn.

Possíveis Problemas:	Poucos exemplos com valor real da transferência em comparação a quantidade total das transferências. Clubes com pouco histórico de transferência. Transferências absurdas que saem do perfil do clube.
	1- treinar o Modelo 2 somente com esses exemplos válidos e usar validação cruzada para garantir que o modelo generaliza bem. 2- Definir uma quantidade mínima de exemplos para calcular o perfil do clube, se não alcançar, utiliza os valores da liga como referência. 3- Usar a mediana invés da média para calcular o perfil de compra, ou remover os registros destoantes na hora de calcular a média.

Resultados Esperados

Métricas a serem atingidas:	Modelo 1: MAE < 20%, R^2 acima de 0.8 Modelo 2: MAE < 30%, R^2 acima de 0.7
Saídas do Projeto	Os dois modelos treinados, gráficos de visualização do modelo via matplotlib, relatório, código no github.

Justificativa

O problema é real e tem resultado verificável. O preço de transferência de um jogador é um dado público, que dá para medir com precisão o quanto o modelo errou em cada caso. Além disso, os dados têm volume suficiente. São mais de 656 mil registros históricos de valor de mercado cobrindo 26 anos, criados pelo transfermarkt, site de maior confiabilidade mundial quando o assunto é valor de mercado de um jogador. E ainda o pipeline vai conter dois modelos, onde o segundo modelo utiliza o primeiro em formato de cascata, e os dois têm uso real. Por fim, o tema é de grande alcance, pois muita gente acompanha futebol no mundo todo.

Fluxograma do Projeto

